Introduction to

UNIDADES DE PORCESAMIENTO NEURONAL

Start

Brena de León Víctor Javier
Cruz Manríquez Lizbeth

INTRODUCCIÓN

Los modelos de aprendizaje profundo requiere grandes capacidades de procesamiento para ejecutarse.

Los procesadores tradicionales (CPU y GPU) pueden ejecutar estos modelos, pero no están optimizados específicamente para ello.

Unidades de Procesamiento Neuronal

Home **Content** Contact

- Unidades de Procesamiento Neuronal (NPU) siendo este un microprocesador especializado diseñado para acelerar operaciones matemáticas asociadas con redes neuronales artificiales y modelos de aprendizaje profundo.

¿QUE ES LA NPU?

CARACTERISTICAS

Sus principales características son:

- procesamiento paralelo masivo
- optimización para operaciones tensoriales
- alta eficiencia energética
- baja latencia

Unidades de Procesamiento Neuronal

Home Content Contact

CPU/GPU/NPU

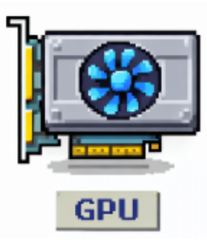

Característica	CPU	GPU	NPU
Propósito	Procesamiento general	Procesamiento gráfico y paralelo	Procesamiento especializado en IA
Tipo de arquitectura	Secuencial con pocos núcleos	Masivamente paralela	Paralelismo optimizado para tensores
Núcleos	2–64	Cientos o miles	Miles de unidades MAC
Precisión típica	FP64, FP32	FP32, FP16	INT8, FP16
Consumo energético	Moderado	Alto	Bajo
Uso principal	Sistema operativo, aplicaciones	Gráficos, entrenamiento IA	Inferencia IA
Eficiencia en IA	Baja	Alta	Muy alta
Movimiento de datos	Alto	Alto	Optimizado

Unidades de Procesamiento Neuronal

Home **Content** Contact

Cerebro humano	**Red neuronal**
Neuronas	Nodos
Sinapsis	Pesos
Plasticidad	Ajuste de pesos
Aprendizaje	Entrenamiento

INSPIRACIÓN

Las NPU no replican el cerebro, pero sí implementan el modelo matemático de las redes neuronales.

Ecuación

$$Y = (W * X) + b$$

OPERACIÓN MATEMÁTICA

Donde
- W = pesos
- X = entradas
- b = sesgo

Las operaciones principales son:
- multiplicación de matrices
- producto punto
- convoluciones

Estas operaciones representan más del 90 % del cálculo en redes neuronales profundas.

$$A = A + (B \times C)$$

UNIDADES MAC

Multiply-Accumulate

Las NPU incluyen miles de unidades MAC que permiten:

- multiplicaciones de matrices
- convoluciones
- cálculo tensorial

Esto permite ejecutar millones de operaciones por segundo.

Formato	Uso
FP32	entrenamiento
FP16	entrenamiento acelerado
INT8	inferencia en NPU

PRECISIÓN NUMÉRICA

Las **NPU usan INT8** porque:

- reduce memoria
- reduce consumo energético
- permite más paralelismo

ARQUITECTURA

Características principales:

- arquitectura tensorial
- paralelismo masivo
- eficiencia energética
- baja latencia

Las NPU pueden integrarse en:

- SoC (System on Chip) → smartphones
- aceleradores dedicados → servidores

COMPONENTES

Núcleos tensoriales
Realizan operaciones matriciales.

Arquitectura sistólica
Permite flujo continuo de datos entre unidades de cálculo.

Memoria on-chip
Reduce accesos a memoria externa.

Controlador DMA
Transfiere datos sin intervención constante de la CPU.

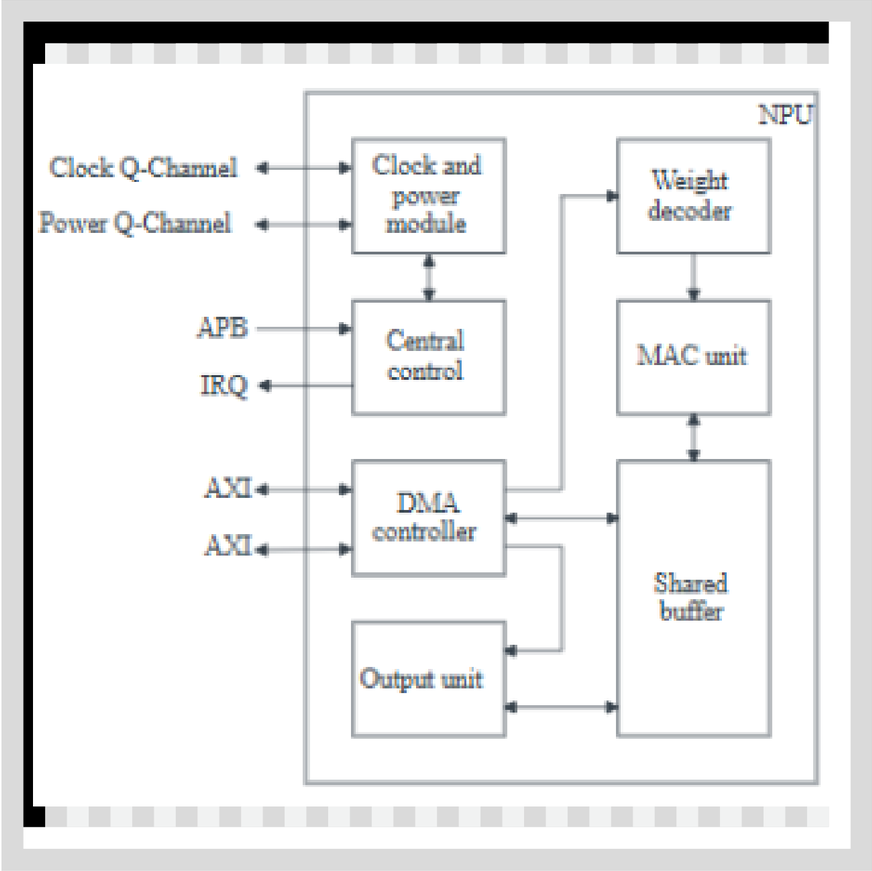

Unidades de Procesamiento Neuronal

Home **Content** Contact

FLUJO DE OPERAIÓN

APLICACIONES

Algoritmos que aceleran:

CNN
- visión artificial
- reconocimiento facial

RNN
- reconocimiento de voz
- procesamiento de lenguaje

Transformers
- modelos de lenguaje
- IA generativa

Aplicaciones:
- smartphones
- vehículos autónomos
- robótica
- IoT
- Edge AI

CONCLUSIONES

Las NPU, por su diseño especializado permite ejecutar modelos de aprendizaje profundo con mayor eficiencia energética y menor latencia que CPU y GPU.

En un contexto donde la inteligencia artificial se integra en dispositivos cotidianos, las NPU se consolidan como un componente esencial para el desarrollo de Edge AI, dispositivos inteligentes y sistemas autónomos.